Statistique Descriptive Univariée

1. Paramètres de position

C'est une valeur d'une distribution d'un caractère statistique quantitatif choisie pour sa représentativité d'une tendance de cette distribution, soit son centre, sa fréquence dominante ou sa position médiane dans l'ensemble des valeurs.

1.1 Le tableau statistique

Une variable quantitative continue peut prendre une infinité de valeurs possibles. Le domaine de la variable est alors $\mathbb{R}$ ou un intervalle de $\mathbb{R}$. En pratique, une mesure est limitée en précision. La taille peut être mesurée en centimètres, voire en millimètres. On peut alors traiter les variables continues comme des variables discrètes. Cependant, pour faire des représentations graphiques et construire le tableau statistique, il faut procéder à des regroupements en classes. Le tableau regroupé en classe est souvent appelé distribution groupée. Si $[c_j^- ; c_j^+ [$ designe la classe j, on note, de manière générale :

$-\ c_j^-$ la borne inférieure de la classe j,

$-\ c_j^+$ la borne supérieure de la classe j,

$-\ c_j^- = (c_j^+ + c_j^-)/2$ le centre de la classe j,

$-\ a_j = c_j^+ - c_j^-$ l'amplitude de la classe j,

$-\ n_j$ l'effectif de la classe j,

$-\ N_j$ l'effectif cumulé de la classe j,

$-\ f_j$ la fréquence de la classe j,

$-\ F_j$ la fréquence cumulée de la classe j.

La répartition en classes des données nécessite de définir a priori le nombre de classes J et donc l'amplitude de chaque classe.

```
X=c(0 , 0 , 1 , 1 , 2 , 2 , 3, 4)
c5cl <- cut(X, 5)
T5=table(c5cl)
T5c=c(T5)
data.frame(Eff=T5c,EffCum=cumsum(T5c),Freq=T5c/sum(T5c),FreqCum=cumsum(T5c/sum(T5c)))
```

A data.frame: 5 × 4

	Eff	EffCum	Freq	FreqCum
	<int>	<int>	<dbl>	<dbl>
(-0.004,0.8]	2	2	0.250	0.250
(0.8,1.6]	2	4	0.250	0.500
(1.6,2.4]	2	6	0.250	0.750
(2.4,3.2]	1	7	0.125	0.875
(3.2,4]	1	8	0.125	1.000

1.2 La moyenne

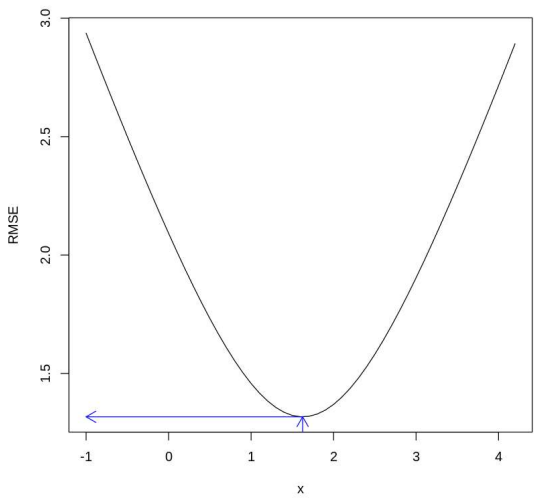
La moyenne est la somme des valeurs observées divisée par leur nombre, elle est notée $\bar{x}$:

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

La moyenne $\bar{x}$ minimise la RMSE (Root Mean Squared Error):

$$RMSE(x) = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x - x_i)^2}$$

```
norm_vec2 <- function(x){sqrt(crossprod(X-x)/length(X))}
moy=mean(X)
x <- seq(-1,4.2,0.1)
RMSE <- NULL
for(i in seq_len(length(x))) {
RMSE[i] <- norm_vec2(x[i])
}
plot(x, RMSE,type="l")
arrows(moy,1.,moy,norm_vec2(moy),length=0.14,col="blue")
arrows(moy,norm_vec2(moy),-1.,norm_vec2(moy),length=0.14,col="blue")
```

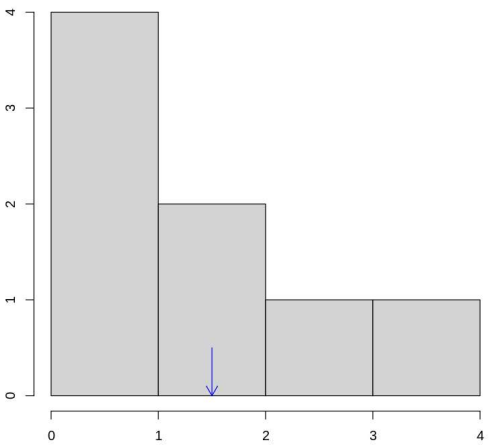


1.3 La médiane

La médiane $x_{1/2}$ est la valeur qui se trouve au milieu de la série des observations ordonnée :

```
m=median(X)
cat("Médiane : ",m)
hist(X,xlab="",ylab="",main="")
arrows(m,0.50,m,0,length=0.14,col="blue")
```

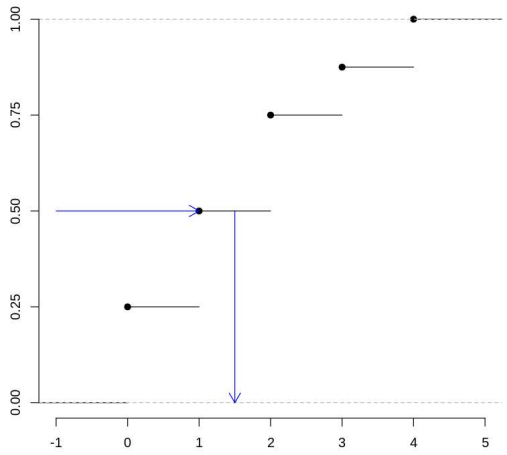
```
Médiane :  1.5
```



La médiane peut être d´efinie comme l'inverse de la fonction de répartition pour la valeur 1/2 :

$$x_{1/2} = F^{-1}(0.5).$$

```
plot(ecdf(X),xlab="",ylab="",main="",frame=FALSE,yaxt = "n")
axis(2, c(0.0,0.25,0.50,0.75,1.00))
arrows(-1,0.5,1,0.50,length=0.14,col="blue")
arrows(m,0.50,m,0,length=0.14,col="blue")
```



1.4 Les quantiles

La notion de quantile d'ordre p (où $0 < p < 1$) généralise la médiane. Formellement un quantile est donné par l'inverse de la fonction de répartition :

$$x_p = F^{-1}(p).$$

Remarque

– La médiane est le quantile d'ordre p = 1/2.

– On utilise souvent

$x_{1/4}$ le premier quartile,

$x_{3/4}$ le troisième quartile,

$x_{1/10}$ le premier décile ,

$x_{1/5}$ le premier quintile,

$x_{4/5}$ le quatrième quintile,

$x_{9/10}$ le neuvième décile,

$x_{0.05}$ le cinquième percentile ,

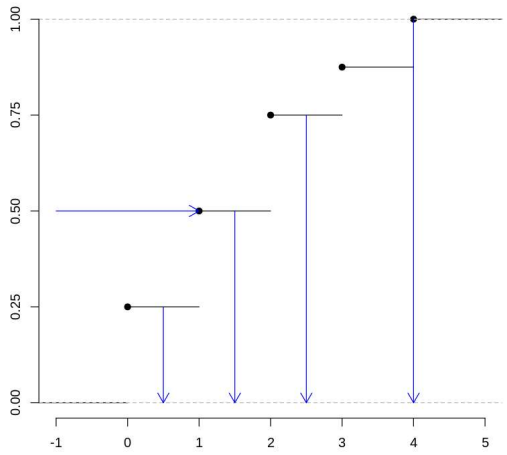
$x_{0.95}$x le quatre vinght quinzième percentile.

– Si $F(x)$ est la fonction de répartition, alors $F(x_p) \geq p$.

```
quantile(X,type=2)
q=quantile(X,type=2)
```

```
      0%:       0 25%:       0.5 50%:       1.5 75%:       2.5 100%:       4
```

```
plot(ecdf(X),xlab="",ylab="",main="",frame=FALSE,yaxt = "n")
axis(2, c(0.0,0.25,0.50,0.75,1.00))
arrows(-1,0.5,1,0.50,length=0.14,col="blue")
arrows(q[2],0.25,q[2],0,length=0.14,col="blue")
arrows(q[3],0.50,q[3],0,length=0.14,col="blue")
arrows(q[4],0.75,q[4],0,length=0.14,col="blue")
arrows(q[5],1.,q[5],0,length=0.14,col="blue")
```



2. Paramètres de dispersion

C'est un nombre qui reflète l'étendue des valeurs d'un caractère statistique quantitatif autour d'un paramètre de position donné, généralement la moyenne.

2.1 L'étendue

L'étendue est simplement la différence entre la plus grande et la plus petite valeur observée.

$$E = \max_{i\in\{1,..,n\}} x_i - \min_{x\in\{1,..,n\}} x_i.$$

2.2 La distance interquartile

La distance interquartile est la diff´erence entre le troisième et le premier quartile :

$$IQ = x_{3/4} - x_{1/4}.$$

2.3 La variance

La variance est la somme des carrés des écarts à la moyenne divisée par le nombre d'observations :

$$s_x^2 = \frac{1}{n}\sum_{i=1}^{n}(x - x_i)^2.$$

2.4 L'écart-type

L'écart-type est la racine carrée de la variance :

$$s_x = \sqrt{s_x^2}.$$

Quand on veut estimer l'écart-type d'une variable X partir d'un échantillon de taille n, on utilise la variance "corrigée" pour définir l'écart type

$$S_x = \sqrt{S_x^2} = s_x\sqrt{\frac{n}{n-1}}.$$

La plupart des logiciels statistiques calculent S_x et non s_x.

Téléchargement des données

Pour télécharger les données, nous utiliserons l'adesse Web: https://s3-api.us-geo.objectstorage.softlayer.net/cf-courses-data/CognitiveClass/ML0101ENv3/labs/FuelConsumptionCo2.csv ensuite nous metterons le fichier téléchargé dans jupyter localhost.

```
smp <- read.csv("FuelConsumptionCo2.csv")
```

```
head(smp)
```

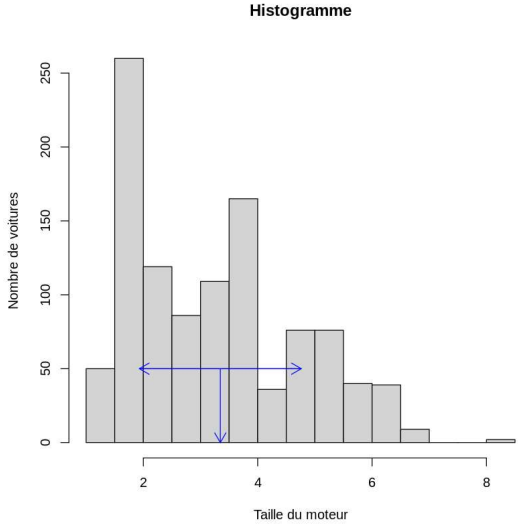
	MODELYEAR	MAKE	MODEL	VEHICLECLASS	ENGINESIZE	CYLINDERS	TRANSMISSION	FUE
	<int>	<chr>	<chr>	<chr>	<dbl>	<int>	<chr>	
1	2014	ACURA	ILX	COMPACT	2.0	4	AS5	
2	2014	ACURA	ILX	COMPACT	2.4	4	M6	
3	2014	ACURA	ILX HYBRID	COMPACT	1.5	4	AV7	
4	2014	ACURA	MDX 4WD	SUV - SMALL	3.5	6	AS6	
5	2014	ACURA	RDX AWD	SUV - SMALL	3.5	6	AS6	
6	2014	ACURA	RLX	MID-SIZE	3.5	6	AS6	

```
c5cl <- cut(smp$ENGINESIZE, 10)
T5=table(c5cl)
T5c=c(T5)
data.frame(Eff=T5c,EffCum=cumsum(T5c),Freq=T5c/sum(T5c),FreqCum=cumsum(T5c/sum(T5c)))
```

A data.frame: 10 × 4

	Eff	EffCum	Freq	FreqCum
	<int>	<int>	<dbl>	<dbl>
(0.993,1.74]	115	115	0.107778819	0.1077788
(1.74,2.48]	258	373	0.241799438	0.3495783
(2.48,3.22]	151	524	0.141518276	0.4910965
(3.22,3.96]	243	767	0.227741331	0.7188379
(3.96,4.7]	85	852	0.079662605	0.7985005
(4.7,5.44]	111	963	0.104029991	0.9025305
(5.44,6.18]	54	1017	0.050609185	0.9531396
(6.18,6.92]	48	1065	0.044985942	0.9981256
(6.92,7.66]	0	1065	0.000000000	0.9981256
(7.66,8.41]	2	1067	0.001874414	1.0000000

```
X=smp$ENGINESIZE
hist(X,xlab="Taille du moteur",ylab="Nombre de voitures",main="Histogramme")
moy=mean(X)
arrows(moy,50,moy,0,length=0.14,col="blue")
std=norm_vec2(moy)
arrows(moy-std,50,moy+std,50,length=0.14,col="blue")
arrows(moy+std,50,moy-std,50,length=0.14,col="blue")
```




```
head(smp[c("CYLINDERS","ENGINESIZE","CO2EMISSIONS","FUELCONSUMPTION_COMB")])
```

A data.frame: 6 × 4

	CYLINDERS	ENGINESIZE	CO2EMISSIONS	FUELCONSUMPTION_COMB
	<int>	<dbl>	<int>	<dbl>
1	4	2.0	196	8.5
2	4	2.4	221	9.6
3	4	1.5	136	5.9
4	6	3.5	255	11.1
5	6	3.5	244	10.6
6	6	3.5	230	10.0

```
summary(smp[c("CYLINDERS","ENGINESIZE","CO2EMISSIONS","FUELCONSUMPTION_COMB")])
```

```
  CYLINDERS        ENGINESIZE     CO2EMISSIONS   FUELCONSUMPTION_COMB
Min.   : 3.000   Min.   :1.000   Min.   :108.0   Min.   : 4.70       
1st Qu.: 4.000   1st Qu.:2.000   1st Qu.:207.0   1st Qu.: 9.00       
Median : 6.000   Median :3.400   Median :251.0   Median :10.90       
Mean   : 5.795   Mean   :3.346   Mean   :256.2   Mean   :11.58       
3rd Qu.: 8.000   3rd Qu.:4.300   3rd Qu.:294.0   3rd Qu.:13.35       
Max.   :12.000   Max.   :8.400   Max.   :488.0   Max.   :25.80       
```