BOX PLOTS

Introduction

Dans ce cahier, nous allons explorer comment créer des boîtes à moustaches dans R. Les boîtes à moustaches sont un moyen pratique de représenter le degré de dispersion (spread) et l'asymétrie des données, et de montrer les valeurs aberrantes sans faire aucune hypothèse sur la distribution statistique sous-jacente. Laissez-nous d'abord installer le package plotly.

```
install.packages("plotly")
library(plotly)
```

Tout d'abord, nous générons des données à représenter avec une boîte à moustaches. Nous utiliserons deux distributions normales avec des paramètres légèrement différents pour générer nos échantillons afin que vous puissiez voir l'effet que cela a sur le tracé.

```
#making the results reproducible
set.seed(1234)

set_a <- rnorm(200, mean=1, sd=2)
set_b <- rnorm(200, mean=0, sd=1)

#create the data frame
df <- data.frame(label = factor(rep(c("A","B"), each=200)), value = c(set_a, set_b))

#output both the first and last rows
head(df)
tail(df)
```

A data.frame: 6 × 2

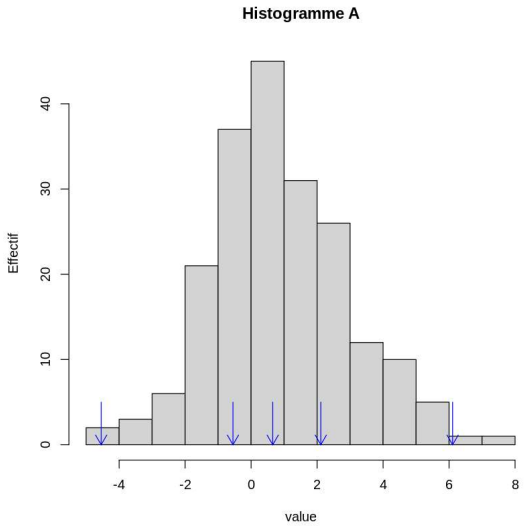
	label	value
	<fct>	<dbl>
1	A	-1.414131
2	A	1.554858
3	A	3.168882
4	A	-3.691395
5	A	1.858249
6	A	2.012112

A data.frame: 6 × 2

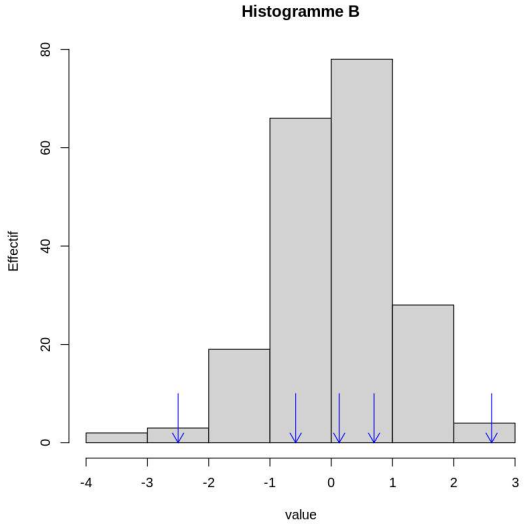
	label	value
	<fct>	<dbl>
395	B	0.52874502
396	B	0.78939440
397	B	0.45709951
398	B	0.53883312
399	B	0.01464312
400	B	-0.91648914

Comme vous pouvez le voir, nous avons généré aléatoirement deux ensembles, les étiquetant respectivement A et B.

```
#quantile(set_a,type=2)
q=quantile(set_a,type=2)
hist(set_a,xlab="value",ylab="Effectif",main="Histogramme A")
IQ=q[4]-q[2]
arrows(q[2]-1.5*IQ,5.,q[2]-1.5*IQ,0,length=0.14,col="blue")
arrows(q[2],5.,q[2],0,length=0.14,col="blue")
arrows(q[3],5.,q[3],0,length=0.14,col="blue")
arrows(q[4],5.,q[4],0,length=0.14,col="blue")
arrows(q[4]+1.5*IQ,5.,q[4]+1.5*IQ,0,length=0.14,col="blue")
```




```
#quantile(set_a,type=2)
q=quantile(set_b,type=2)
hist(set_b,xlab="value",ylab="Effectif",main="Histogramme B")
IQ=q[4]-q[2]
arrows(q[2]-1.5*IQ,10.,q[2]-1.5*IQ,0,length=0.14,col="blue")
arrows(q[2],10.,q[2],0,length=0.14,col="blue")
arrows(q[3],10.,q[3],0,length=0.14,col="blue")
arrows(q[4],10.,q[4],0,length=0.14,col="blue")
arrows(q[4]+1.5*IQ,10.,q[4]+1.5*IQ,0,length=0.14,col="blue")
```

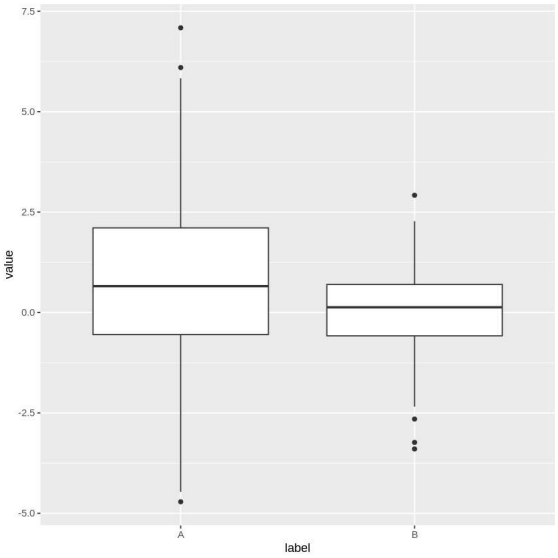


geom_bloxplot()

Nous créons un tracé avec la fonction ggplot et spécifions les axes x et y du tracé. Ensuite, nous ajoutons la boîte à moustaches à notre tracé, ce qui entraîne la création d'une boîte à moustaches pour chaque valeur de x.

```
ggplot(df, aes(x=label, y=value)) + geom_boxplot()
```

```
ggplotly()
```



Passons maintenant à une brève explication de ce qu'est une boîte à moustaches, pour ceux qui ne savent pas

Comme cela a été brièvement mentionné dans la section Introduction, les boîtes à moustaches sont bonnes pour indiquer la dispersion. Ils le font en fournissant des représentations visuelles en termes de quartiles.

- La ligne la plus épaisse au milieu du rectangle représente la valeur médiane (deuxième quartile).
- Le bas et le haut du rectangle représentent respectivement les premier et troisième quartiles.
- La hauteur du rectangle est égale au IQR (plage interquartile), qui est la différence entre les premier et troisième quartiles.
- La ligne supérieure atteint jusqu'à la plus grande valeur qui n'est pas supérieure à 1,5*IQR; Les valeurs plus grandes sont considérées comme des valeurs aberrantes et représentées sous forme de points. (la ligne inférieure est analogue).

BOX PLOTS sur l'ensemble de données mtcars

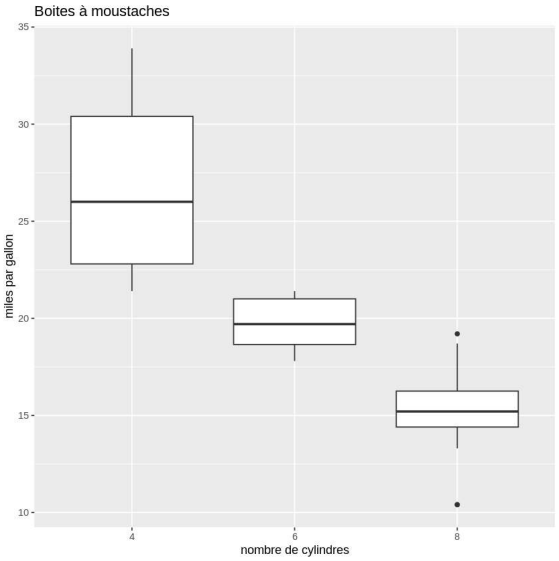
Entraînons-nous avec l'ensemble de données mtcars du monde réel, qui contient des données sur les automobiles de 1973 à 1974.

```
summary(mtcars)
```

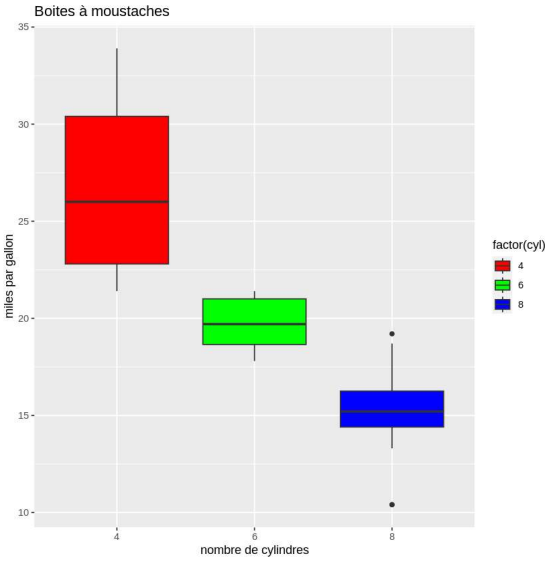
```
      mpg             cyl             disp             hp       
 Min.   :10.40   Min.   :4.000   Min.   : 71.1   Min.   : 52.0  
 1st Qu.:15.43   1st Qu.:4.000   1st Qu.:120.8   1st Qu.: 96.5  
 Median :19.20   Median :6.000   Median :196.3   Median :123.0  
 Mean   :20.09   Mean   :6.188   Mean   :230.7   Mean   :146.7  
 3rd Qu.:22.80   3rd Qu.:8.000   3rd Qu.:326.0   3rd Qu.:180.0  
 Max.   :33.90   Max.   :8.000   Max.   :472.0   Max.   :335.0  
      drat             wt             qsec             vs        
 Min.   :2.760   Min.   :1.513   Min.   :14.50   Min.   :0.0000  
 1st Qu.:3.080   1st Qu.:2.581   1st Qu.:16.89   1st Qu.:0.0000  
 Median :3.695   Median :3.325   Median :17.71   Median :0.0000  
 Mean   :3.597   Mean   :3.217   Mean   :17.85   Mean   :0.4375  
 3rd Qu.:3.920   3rd Qu.:3.610   3rd Qu.:18.90   3rd Qu.:1.0000  
 Max.   :4.930   Max.   :5.424   Max.   :22.90   Max.   :1.0000  
       am              gear            carb      
 Min.   :0.0000   Min.   :3.000   Min.   :1.000  
 1st Qu.:0.0000   1st Qu.:3.000   1st Qu.:2.000  
 Median :0.0000   Median :4.000   Median :2.000  
 Mean   :0.4062   Mean   :3.688   Mean   :2.812  
 3rd Qu.:1.0000   3rd Qu.:4.000   3rd Qu.:4.000  
 Max.   :1.0000   Max.   :5.000   Max.   :8.000  
```

Nous allons travailler avec les deux premières variables de la rangée supérieure: miles par gallon et nombre de cylindres. Commençons par créer une boîte à moustaches à l'aide de qplot. Puisque le nombre de cylindres est plus une catégorie qu'un attribut numérique, nous allons appliquer la fonction 'facteur'. Les voitures sont soit 4 cylindres, 6 cylindres ou 8 cylindres. Pour l'axe y, nous utiliserons les données de miles par gallon. Et vous pouvez voir que nous obtenons une boîte à moustaches pour chaque catégorie de cylindre.

```
qplot(factor(cyl),mpg,data=mtcars,geom="boxplot",xlab="nombre de cylindres",ylab="miles par gallon", main="Boites à moustaches")
```




```
qplot(factor(cyl),mpg,data=mtcars,geom="boxplot",xlab="nombre de cylindres",ylab="miles par gallon", main="Boites à moustaches", aes(fill
  scale_fill_manual(values = c("red", "green", "blue"))
```



BOX PLOTS sur l'ensemble de données belgianmunicipalities

On utilise une base de données belges fournie par l'Institut National (belge) de Statistique contenant des informations sur la population et les revenus des personnes physiques dans les communes. On s'intéresse à la variable "revenu moyen en euros par habitant en 2004" pour chaque commune (variable averageincome) et l'on aimerait comparer les 9 provinces belges : Anvers, Brabant, Flandre occidentale, Flandre orientale, Hainaut, Li`ege, Limboug, Luxembourg, Namur. La Figure ci-dessus contient les boîtes à moustaches de chaque province. Les communes ont été triées selon les provinces belges. De ce graphique, on peut directement voir que la province du Brabant contient à la fois la commune la plus riche (Lasne) et la plus pauvre (Saint-Josse-ten-Noode). On voit également une dispersion plus importante dans la province du Brabant.

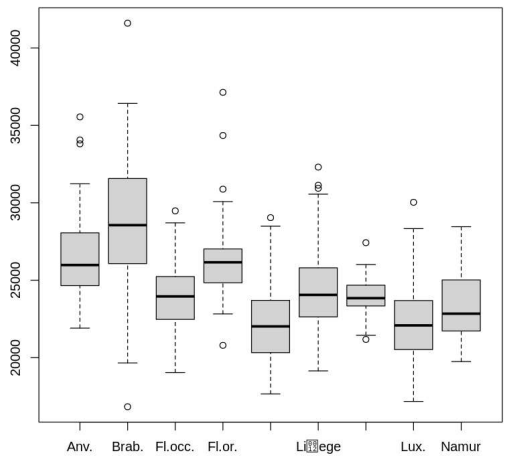
```
install.packages("sampling")
```

```
    Installing package into '/usr/local/lib/R/site-library'
    (as 'lib' is unspecified)

    also installing the dependency 'lpSolve'
```

```
library(sampling)
```

```
data(belgianmunicipalities)
attach(belgianmunicipalities)
# Construction d'une liste avec les noms des provinces
b=list(
"Anv."=averageincome[Province==1],
"Brab."=averageincome[Province==2],
"Fl.occ."=averageincome[Province==3],
"Fl.or."=averageincome[Province==4],
"Hainaut"=averageincome[Province==5],
"Li?ege"=averageincome[Province==6],
"Limb."=averageincome[Province==7],
"Lux."=averageincome[Province==8],
"Namur"=averageincome[Province==9]
)
boxplot(b)
```



Courbe de Lorenz-Indice de Gini

En économie, la **courbe de Lorenz** est une représentation graphique de la répartition des revenus ou de la richesse. Il a été développé par Max O. Lorenz en 1905 pour représenter l'inégalité de la répartition des richesses.

La courbe est un graphique montrant la proportion du revenu global ou de la richesse assumée par les x % inférieurs de la population. Il est souvent utilisé pour représenter la distribution des revenus, où il montre pour les x% inférieurs de ménages, quel pourcentage (y%) du revenu total dont ils disposent. Le pourcentage de ménages est porté en abscisse, le pourcentage de revenu en ordonnée. Il peut également être utilisé pour montrer la répartition des actifs. Dans une telle utilisation, de nombreux économistes le considèrent comme une mesure de l'inégalité sociale.

L'**Indice de Gini** mesure l'inégalité entre les valeurs d'une distribution de fréquence (par exemple, les niveaux de revenu). Un coefficient de Gini de zéro exprime une égalité parfaite, où toutes les valeurs sont les mêmes (par exemple, où tout le monde a le même revenu). Un coefficient de Gini de un (ou 100 %) exprime l'inégalité maximale entre les valeurs (par exemple, pour un grand nombre de personnes où une seule personne a tout le revenu et toutes les autres n'en ont pas, le coefficient de Gini sera proche de un).

Exemple 1

```
X=c(620, 650, 690, 730, 760, 800, 800, 850, 900, 950, 1000, 1050, 1100, 1150, 1190,
    1210, 1220, 1240, 1300, 1320, 1360, 1400, 1420, 1440, 1480, 1500, 1540, 1580, 1620, 1660, 1700, 1710, 1720, 1730, 1740, 1760, 1770,
    1810, 1840, 1880, 1920, 1960, 2000, 2040, 2060, 2080, 2090)
c5cl <- cut(X, c(600, 1200, 1800, 2100))
T5=table(c5cl)
T5c=c(T5)
data.frame(Eff=T5c,EffCum=cumsum(T5c),Freq=T5c/sum(T5c),FreqCum=cumsum(T5c/sum(T5c)))
```

A data.frame: 3 × 4

	Eff	EffCum	Freq	FreqCum
	<int>	<int>	<dbl>	<dbl>
(600,1.2e+03]	15	15	0.3	0.3
(1.2e+03,1.8e+03]	25	40	0.5	0.8
(1.8e+03,2.1e+03]	10	50	0.2	1.0

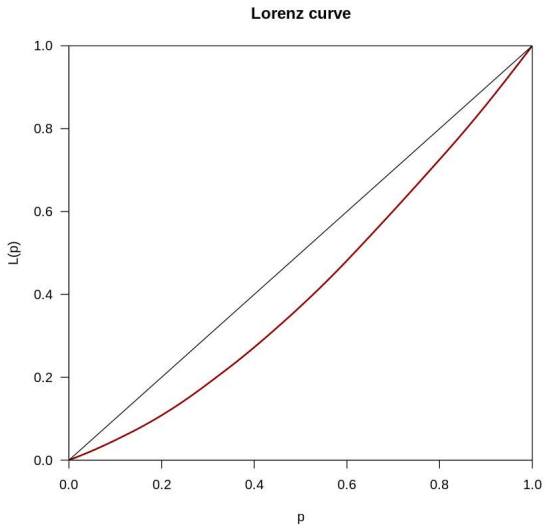
```
install.packages("ineq")
library(ineq)
```

```
Installing package into ‘/usr/local/lib/R/site-library’
(as ‘lib’ is unspecified)
```

```
ineq(X,type="Gini")
```

```
0.171688166794505
```

```
plot(Lc(X),col="darkred",lwd=2)
```




```
X=c(900, 900, 900, 900, 900, 900, 900, 900, 900, 900, 900, 900, 900, 900, 900,
    1500, 1500, 1500, 1500, 1500, 1500, 1500, 1500, 1500, 1500, 1500, 1500, 1500, 1500, 1500, 1500, 1500, 1500, 1500, 1500,
    1950, 1950, 1950, 1950, 1950, 1950, 1950, 1950, 1950, 1950)
c5cl <- cut(X, c(600, 1200, 1800, 2100))
T5=table(c5cl)
T5c=c(T5)
data.frame(Eff=T5c,EffCum=cumsum(T5c),Freq=T5c/sum(T5c),FreqCum=cumsum(T5c/sum(T5c)))
```

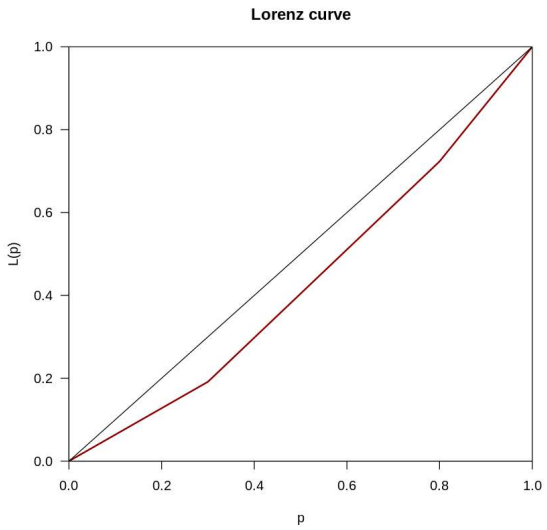
A data.frame: 3 × 4

	Eff	EffCum	Freq	FreqCum
[1.2e+03,1.8e+03]	25	40	0.5	0.8

```
ineq(X,type="Gini")
```

0.140425531914894

```
plot(Lc(X),col="darkred",lwd=2)
```



Exemple 2

On utilise une enquête ménage sur le revenu dans une région des Philippines appelée **Ilocos**. Cette enquête de 1997 sur le revenu des ménages a été produite par l'Office philippin de Statistique. La courbe de Lorenz est présentée

```
data(Ilocos)
```

```
head(Ilocos)
```

A data.frame: 6 × 8

	income	sex	family.size	urbanity	province	AP.income	AP.family.size	AP.weig
	<dbl>	<fct>	<dbl>	<fct>	<fct>	<dbl>	<dbl>	<db
1	133582	male	5.5	urban	Ilocos Norte	153924.0	5	38
2	312800	male	1.0	urban	Ilocos Norte	164531.5	1	38
3	395434	male	6.0	urban	Ilocos Norte	195892.4	5	38
4	519235	female	10.0	urban	Ilocos Norte	358701.0	10	38

```
X=Ilocos$income
ineq(X,type="Gini")
```

0.426950770210349

```
plot(Lc(X),col="darkred",lwd=2)
```

