Chapitre 4 : Codage des nombres réels

Hassen NAKBI :: hassen.nakbi@gmail.com

1ere année Licence en mathématiques

16 novembre 2023

Introduction

Un nombre réel

- Un nombre réel représente un nombre rationnel $\mathbb{Q}$ en mathématique. Il peut s'écrire sous la forme d'une fraction $\frac{a}{b}$ avec a $\in \mathbb{Z}$ et b $\in \mathbb{N}^*$.
- Étant donné que la partie fractionnaire représente la précision des chiffres après la virgule et n'est pas finie, elle peut présenter un développement périodique.
- Ce chapitre vise à représenter de manière numérique le résultat d'une fraction composée d'une partie entière, suivie d'un point (ou d'une virgule), puis d'une partie fractionnaire.

2 Codage d'un réel non signé

- Codage de précision
- Conversion d'un réel décimal vers une base B
- Conversion d'un réel base B vers le décimal

Précision arbitraire

Coder un réel non signé avec une taille de bits infinie n'est pas possible, car une taille de bits infinie nécessiterait une mémoire infinie pour stocker l'information. Cependant, nous pouvons utiliser une précision arbitraire pour représenter un réel avec une taille de bits suffisamment grande.

2 Codage d'un réel non signé
- Codage de précision
- Conversion d'un réel décimal vers une base B
- Conversion d'un réel base B vers le décimal

Conversion d'un réel décimal vers une base B

Conversion de réel décimal vers une base B

Pour représenter la partie fractionnaire dans une base B, nous multiplions de manière répétitive la partie fractionnaire trouvée par la base B, en notant à chaque itération la partie entière obtenue, jusqu'à ce que la partie fractionnaire devienne nulle ou que la précision souhaitée soit atteinte. La partie fractionnaire résultante est la concaténation des parties entières, exprimées en base B, dans l'ordre de leur calcul.

Conversion d'un réel décimal vers une base B

Exemple 1 : Conversion d'un réel décimal vers le binaire

$15{,}9625_{10}$ en binaire

15 MOD 2 = 1

7 MOD 2 = 1

3 MOD 2 = 1

1 MOD 2 = 1

$15_{10} = 1111_2$

0,9625 * 2=**1**,925

0,925 * 2=**1**,85

0,85 * 2=**1**,7

0.7 * 2=**1**,4

0.4*2=**0**,8

0.8*2=**1**,6

0.6*2=**1**,2

0.2*2=**0**,4

$15{,}9625_{10} = 1111{,}\mathbf{1111}\overline{0110}_2$

Conversion d'un réel décimal vers une base B

Exemple 2 : Conversion d'un réel décimal vers l'octal

$\frac{1}{3} = 0{,}3333_{10}$ en octal

0,3333 * 8 =**2**,6664
0,6664 * 8 =**5**,3312
0,3312 * 8 =**2**,6496
0,6496 * 8 =**5**,1968
0,1968 * 8 =**1**,5744
0,5744 * 8 =**4**,5952
0,5952 * 8 =**4**,7616
0,7616 * 8 =**6**,0928
0,0928 * 8 =**0**,7424
0,7424 * 8 =**5**,9392
0,9392 * 8 =**7**,5136
0,5136 * 8 =**4**,1088
0,1088 * 8 =**0**,8704
0,8704 * 8 =**6**,9632
0,9632 * 8 =**7**,7056
0,7056 * 8 =**5**,6448

$0{,}3333_{10} = 0{,}\mathbf{2525144605740675}_{8}$

Conversion de décimal vers une base B

Exemple 3 : Conversion de décimal vers l'hexadécimal

$68,79584_{10}$ en hexadécimal

68 MOD 16 = 4

4 MOD 16 = 4

$68_{10} = 44_{16}$

0,79584 * 16 =**C**,73344
0,73344 * 16 =**B**,73504
0,73504 * 16 =**B**,76064
0,76064 * 16 =**C**,17024
0,17024 * 16 =**2**,72384
0,72384 * 16 =**B**,58144
0,58144 * 16 =**9**,30304
0,30304 * 16 =**4**,84864
0,84864 * 16 =**6**,78912
0,78912 * 16 =**C**,62592
0,62592 * 16 =**A**,01472

$68,79584_{10} = 44,\mathbf{CBBC2B946CA}_{16}$

2 Codage d'un réel non signé

- Codage de précision
- Conversion d'un réel décimal vers une base B
- Conversion d'un réel base B vers le décimal

Conversion d'un réel base B vers le décimal

Conversion d'un réel base B vers le décimal

La partie entière est exprimée sous forme de chiffres de base à des puissances positives, en commençant par la puissance zéro de droite à gauche. La partie fractionnaire est exprimée sous forme de chiffres de base à des puissances négatives, en commençant par la puissance -1 de gauche à droite. La conversion est calculée par une suite de multiplications des puissances par les chiffres correspondants, suivies de la somme des produits partiels.

Conversion d'un réel base B vers le décimal

Exemple 1 : Conversion d'un réel binaire vers le décimal

$101,0101_2$ en décimal

$101_2 = 2^2*1+2^1*0+2^0*1$

$101_2 = 4 + 0 + 1$

$101_2 = 5_{10}$

$101,0101_2 = 5,\mathbf{3125}_{10}$

$\mathbf{,0101}_2 =$

$\mathbf{2}^{-1}*0+\mathbf{2}^{-2}*1+\mathbf{2}^{-3}*0+\mathbf{2}^{-4}*1$

$,0101_2 = 0+0.25+0+0.0625$

$,0101_2 = 0,3125_{10}$

Conversion d'un réel base B vers le décimal

Exemple 2 : Conversion d'un réel octal vers le décimal

$76,5432_8$ en décimal

$76_8 = 8^1*7+8^0*6$

$76_8 = 56 + 6$

$76_2 = 62_{10}$

$,5432_8 =$

$8^{-1}*5+8^{-2}*4+8^{-3}*3+8^{-4}*2$

$,5432_8 =$

$0.625+0.0625+0.005859+0.00024414$

$,5432_8 = 0,693603140625_{10}$

$76,5432_8 = 62,693603140625_{10}$

Conversion d'un réel base B vers le décimal

Exemple 3 : Conversion d'un réel hexadécimal vers le décimal

$CB,7654_{16}$ en décimal

$CB_{16} = 16^1*12+16^0*11$

$CB_{16} = 192 + 11$

$CB_{16} = 203_{10}$

$,7654_{16} =$

$16^{-1}*7+16^{-2}*6+16^{-3}*5+16^{-4}*4$

$,7654_{16} = 0,4375+0,0234375+$

$0,0012207+0,000061035$

$,7654_{16} = 0,462219235_{10}$

$CB,7654_{16} = 203,462219235_{10}$

3 Codage d'un réel signé
- Codage signé
- Codage virgule fixe
- Codage virgule flottante
- Norme IEEE 754

Codage signé

Le codage d'un réel signé implique l'inclusion d'un bit de signe dans la représentation binaire du nombre. Par ailleurs, la précision d'un réel dépend étroitement de la taille binaire allouée en fonction de la plage de valeurs que le système doit traiter.
Il existe deux méthodes de codage pour représenter les nombres réels :

1. Codage virgule fixe.
2. Codage virgule flottante.

3 Codage d'un réel signé
- Codage signé
- Codage virgule fixe
- Codage virgule flottante
- Norme IEEE 754

Codage virgule fixe

Le codage fixe est une méthode de représentation des nombres réels en utilisant un nombre fixe de bits pour la partie entière et la partie fractionnaire. Il est utilisé pour représenter des nombres réels dans des environnements où la précision et la taille de la mémoire sont des considérations critiques.
L'intervalle des valeurs réelles signées représentables, une partie entière sur n bits, avec un bit de signe et une partie fractionnaire sur p bits : $-2^{(n-1)}-2^{-p} \leq R \leq +2^{(n-1)}-2^{-p}$

Codage virgule fixe

Si n = 4 bits et p = 4 bits, alors la valeur réelle sera codée sur 8 bits. L'intervalle des valeurs représentables : [-7.9375, +7.9375]

-7,3157$_{10}$ en binaire
7 MOD 2 = 1
3 MOD 2 = 1
1 MOD 2 = 1
-7$_{10}$ = 1001$_2$

0,3157 * 2=**0**,6314
0,6314 * 2=**1**,2628
0,2628 * 2=**0**,5256
0,5256 * 2=**1**,0512

-7,3157$_{10}$ = 1001,**0101**$_2$

Codage virgule fixe

1. **Avantages**
   - Le codage fixe est plus simple à mettre en oeuvre.
   - Le codage fixe peut être plus efficace en termes de ressources de traitement.
   - Les opérations arithmétiques peuvent être plus rapides dans certains cas, car les calculs impliquent un nombre fixe de bits.
2. **Inconvénients**
   - La précision est fixée, ce qui peut entraîner des erreurs d'approximation.
   - Elle ne permet pas de représenter des réels très grands ou très petits.

3 Codage d'un réel signé

- Codage signé
- Codage virgule fixe
- Codage virgule flottante
- Norme IEEE 754

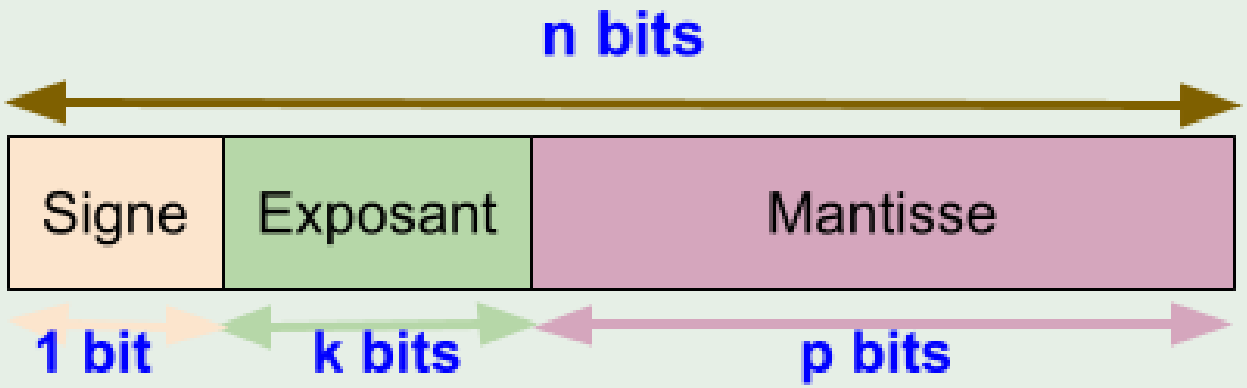
Codage virgule flottante

La méthode de virgule flottante est une représentation des nombres réels. Inspirée de la notation scientifique, elle utilise une structure à deux composantes, associant une mantisse et un exposant, pour exprimer des nombres de manière compacte et précise.

Concepts clés

- La mantisse, également appelée fraction, représente la partie significative du nombre. Elle est composée de bits qui expriment la précision du nombre réel.
- L'exposant indique la puissance de la base à laquelle la mantisse est élevée. Il permet d'ajuster la magnitude du nombre et de représenter des valeurs très grandes ou très petites de manière efficace.
- Un seul bit est réservé pour indiquer le signe du nombre.

Structure d'un réel



Codage virgule flottante

Le codage d'un nombre réel R en virgule flottante se fait sous la forme suivante : $\mathbf{R = \pm M \times B^{\pm e}}$

- M : est la mantisse qui représente la partie fractionnaire.
- $\pm$: est le signe de la mantisse $\in \{-1,+1\}$.
- B : est la base de codage utilisée pour un réel.
- e : est l'exposant qui donne l'ordre de grandeur.

Exposant décalé ou biaisé

Avec des exposants signés, la comparaison entre les réels flottants est assez difficile. L'intervalle des valeurs relatives en complément à deux sur k bits sont comprises entre $-2^{k-1} \leq R \leq +2^{k-1}-1$.
Pour négliger les valeurs négatives, on rajoute la valeur 2^{k-1} à tout les termes de cette inégalité, ce qui nous donne des valeurs positives avec le biais ou décalage de 2^{k-1}.

Exposant décalé ou biaisé

Pour calculer l'exposant biaisé, il faut ajouter à l'exposant réel une valeur de décalage 2^{k-1} de manière suivante :

Exposant décalé = Exposant réel + biais

3 Codage d'un réel signé

- Codage signé
- Codage virgule fixe
- Codage virgule flottante
- Norme IEEE 754

Virgule flottante normalisée

La norme internationale IEEE 754 a été adoptée par la majorité des constructeurs des matériel informatique pour représenter des nombres réels binaires sous forme flottante. Elle a définit trois formats de représentation :

- Simple précision codé sur 32 bits.
- Double précision codé sur 64 bits.
- Précision étendue codé sur 80 bits.

La norme IEEE 754 utilise un bit caché pour la mantisse et l'exposant est décalé par un biais 2^{k-1} - 1.

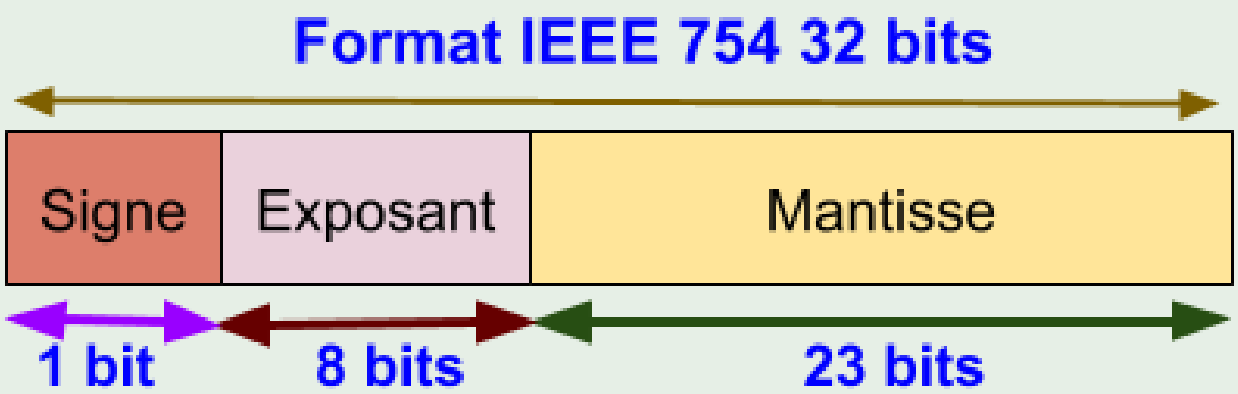
Format IEEE 754 en simple précision

Le format IEEE 754 en simple précision, également connu sous le nom de virgule flottante à 32 bits, est une norme largement utilisée pour représenter les nombres réels en langage de programmation C avec le type float.
Le codage se réalise sur une taille 32 bits, répartis comme suit :

- Signe codé sur un seul bit à gauche.
- Exposant biaisé et codé sur 8 bits.
- Mantisse codée sur 23 bits.
- Le biais de décalage de l'exposant est toujours 127.

Les valeurs de l'exposant réel sans décalage $\in$ [-126,+127]

Format IEEE 754 en simple précision



Application

Format IEEE 754 en simple précision

Coder en binaire le réel -0,62510 en simple précision avec le format IEEE 754 en simple précision.

0,625 s'écrit en binaire : $0{,}101 = 1{,}01 \times 2^{-1}$

- Signe : négatif(1)
- Mantisse normalisée : 1,01000000000000000000000
- Biais de décalage : 127
- Exposant biaisé : -1 + 127 = 126 = 1111110

$-0{,}625_{10} = \mathbf{10111111001000000000000000000000}_2$

Application

Format IEEE 754 en simple précision

Coder en binaire le réel -2,625 en simple précision avec le format IEEE 754 en simple précision.

-2,625 s'écrit en binaire : $10{,}101 = 1{,}0101 \times 2^{+1}$

- Signe : négatif(1)
- Mantisse normalisée : 1,01010000000000000000000
- Biais de décalage : 127
- Exposant biaisé : $1 + 127 = 128 = 10000000$

$-2{,}625_{10} = 11000000010100000000000000000000_2$

Application

Format IEEE 754 en simple précision

Coder en décimal le réel $01000001011000000000000000000000_2$ en simple précision avec le format IEEE 754 en simple précision.

- $0\mathbf{10000010}\mathbf{11000000000000000000000}$
- Signe : positif(0) = +
- Mantisse normalisée : 1,11000000000000000000000
- Biais de décalage : 127
- Exposant biaisé : 10000010 = 130
- Exposant réel : 130 - 127 = 3

$01000001011000000000000000000000_2 = \mathbf{1,11 \times 2^3 = 1,75 \times 2^3 = 14,0_{10}}$

Application

Format IEEE 754 en simple précision

Coder en décimal le réel $41BD6666_{16}$ en simple précision avec le format IEEE 754 en simple précision.

- 0**10000011**01111010110011001100110
- Signe : positif(0) = +
- Mantisse normalisée : 1,01111010110011001100110
- Biais de décalage : 127
- Exposant biaisé : 10000011 = 131
- Exposant réel : 131 - 127 = 4

$01000001101111010110011001100110_2$
$= \mathbf{1,01111010110011001100110} \times \mathbf{2^4} = \mathbf{1,47968745} \times \mathbf{2^4} = \mathbf{23,675}_{10}$